
Qualité de sommeil et Performance Cognitive des Étudiants

Rapport d'analyse de données

Auteurs :	Hanine Zellama Youssef Boumaiza Malek Louati
Github :	github.com/youssefb04/Projet_initialisation_traitement_donnees
Dataset :	Sleep Health & Lifestyle Dataset (100 000 individus, 32 variables)
Sous-population :	14 851 étudiants filtrés
Variable cible :	<code>cognitive_performance_score</code> $\in [0, 100]$
Méthode :	Régression linéaire OLS avec features composites
Résultats :	$R^2 = 0.723$, RMSE = 11.10 pts, CV $R^2 = 0.7227 \pm 0.0096$

Contents

1	Business Goal	2
1.1	Description du dataset	2
1.2	Pourquoi ce dataset est-il utile ?	2
2	Organisation de l'équipe	2
2.1	Composition et rôles	2
2.2	Organisation du travail	3
2.3	Outils utilisés	3
3	Visualisation des données	3
3.1	Analyse de corrélation — données numériques	3
3.2	Probabilités conditionnelles — données catégorielles	4
4	Handcrafted Features	5
4.1	Motivation et approche	5
4.2	Construction des quatre features composites	5
4.3	Validation des features composites	6
4.4	Analyse multidimensionnelle des features composites	6
5	Régression linéaire	8
5.1	Choix du type de régression	8
5.2	Équation du modèle final	8
5.3	Résultats et coefficients	8
5.4	Diagnostic des résidus et validation des hypothèses	9
5.5	Validation croisée à 10 plis	10
6	Conclusion	10
6.1	Apports de cette analyse	10
6.2	Limites et pistes d'amélioration	10

1. Business Goal

1.1. Description du dataset

Le dataset utilisé est le *Sleep Health & Lifestyle Dataset* [1], un jeu de données synthétique mais réaliste regroupant 100 000 enregistrements individuels sur 32 variables. Il couvre un large spectre d'attributs physiologiques, comportementaux et contextuels liés au sommeil et à l'activité quotidienne.

Pour ce projet, nous avons filtré le dataset afin de ne conserver que les **14 851 enregistrements** correspondant à des étudiants. Cette décision repose sur un constat préliminaire : les étudiants présentent des habitudes de sommeil systématiquement plus dégradées que les autres professions du dataset — nuits plus courtes, score de qualité de sommeil plus faible, scores de stress plus élevés. En analysant la distribution du `cognitive_performance_score` par occupation, on observe que les étudiants affichent des scores moyens inférieurs à plusieurs autres groupes, ce qui confirme la pertinence d'une analyse ciblée sur cette sous-population.

Les variables clés incluent : la durée de sommeil (heures), le score de qualité de sommeil (échelle 0–10), les pourcentages de sommeil REM et profond, la latence d'endormissement, le nombre de réveils nocturnes, le score de stress, l'état de santé mentale, les heures de travail, les habitudes d'exercice, la consommation d'alcool avant le coucher, et le `cognitive_performance_score` $\in [0, 100]$, qui constitue notre variable cible.

1.2. Pourquoi ce dataset est-il utile ?

Question de recherche : Comment les étudiants peuvent-ils améliorer leur qualité de sommeil afin d'augmenter leur performance cognitive ?

Les étudiants sont une population particulièrement vulnérable au manque de sommeil : pression académique, horaires irréguliers, stress chronique et comportements défavorables au repos en font un groupe pour lequel une analyse explicative est directement actionnable. Ce dataset est utile pour trois raisons :

1. Il couvre l'intégralité de l'architecture du sommeil (REM, sommeil profond, latence, réveils), permettant une modélisation holistique de la qualité du sommeil.
2. Il inclut des variables contextuelles (stress, santé mentale, heures de travail, exercice, alcool) qui capturent le contexte psychologique et comportemental plus large [3].
3. Avec 14 851 enregistrements étudiants, il offre une puissance statistique suffisante pour une inférence fiable et une validation croisée robuste [4].

L'objectif n'est pas seulement de prédire la performance cognitive, mais d'identifier et de quantifier quels facteurs l'expliquent, afin de formuler des recommandations fondées sur les données à destination des étudiants et des institutions.

2. Organisation de l'équipe

2.1. Composition et rôles

Notre équipe est composée de trois étudiants inscrits en MAM3 à l'Université Côte d'Azur :

- **Hanine Zellama** — exploration des données, analyse de corrélations, figures, rédaction des sections 3 et 4.
- **Youssef Boumaiza** — ingénierie des features, modélisation, validation croisée, rédaction des sections 5 et 6.
- **Malek Louati** — visualisation des données, présentation orale, rédaction des sections 1 et 2.

2.2. Organisation du travail

Le projet a été réalisé sur **quatre jours** de travail intensif, en collaboration continue entre les trois membres de l'équipe :

Jour	Tâches réalisées
Jour 1	Recherche et sélection du dataset, définition du business goal, filtrage de la sous-population étudiante, exploration des statistiques descriptives.
Jour 2	Analyse exploratoire des données : calcul des corrélations de Pearson, analyse des probabilités conditionnelles, visualisation 3D.
Jour 3	Sélection et construction des features composites, ajustement du modèle de régression linéaire OLS, diagnostic des résidus.
Jour 4	Optimisation des résultats, validation croisée, rédaction de la conclusion, préparation de la présentation orale.

2.3. Outils utilisés

Python 3 avec les bibliothèques `pandas`, `numpy`, `scikit-learn` [5], `scipy` et `matplotlib` ; Visual Studio Code pour le développement ; Git pour le contrôle de version ; $\text{\LaTeX}$ pour la rédaction du rapport.

3. Visualisation des données

3.1. Analyse de corrélation — données numériques

Avant toute modélisation, nous avons calculé les corrélations de Pearson entre toutes les variables numériques et la variable cible (`cognitive_performance_score`).




Figure 1: Corrélations de Pearson de toutes les variables numériques avec `cognitive_performance_score` (population étudiante, $N = 14851$). Barres vertes : relation positive ; barres rouges : relation négative.

La variable `sleep_quality_score` présente la corrélation la plus élevée ($r = +0.84$), ce qui en fait le prédicteur individuel le plus puissant. La variable `sleep_disorder_enc` suit avec $r = -0.68$: un trouble du sommeil pénalise fortement la performance cognitive [3]. Le `stress_score` ($r = -0.53$) confirme le rôle délétère du stress chronique. En revanche, des variables comme l'âge ($r = -0.05$), le BMI ($r = -0.05$) ou la caféine ($r = -0.08$) présentent des corrélations négligeables et seront éliminées.

3.2. Probabilités conditionnelles — données catégorielles

Pour les variables catégorielles, nous avons analysé la distribution conditionnelle du score cognitif par modalité, complétée par des tests statistiques formels (ANOVA, test t).




Figure 2: Probabilité conditionnelle $P(\text{cognitive_score} \mid \text{variable catégorielle})$ pour six variables. Les tests ANOVA et t valident la significativité statistique de chaque différence observée.

Les résultats sont éloquentes. La **condition de santé mentale** structure fortement la performance : les étudiants en bonne santé atteignent une moyenne de 61,2 points, contre seulement 33,8 pour ceux souffrant d’anxiété et de dépression combinées (ANOVA : $p < 0.001$). Le **risque de trouble du sommeil** montre une relation dose-réponse claire : de 69,0 pour les « Healthy » à 20,2 pour les « Severe » (ANOVA : $p < 0.001$). Le **type de jour** induit également une différence significative (t -test : $p < 0.001$, moyennes 50,7 vs 68,7). En revanche, la **saison** ($p = 0.491$) et le **genre** ($p = 0.792$) ne présentent pas de différences significatives et sont exclus de la modélisation.

4. Handcrafted Features

4.1. Motivation et approche

Après élimination des variables à corrélation trop faible ($|r| < 0.10$), il reste 15 variables candidates sur 32. Nous construisons **4 features composites** sémantiquement cohérentes plutôt que de les intégrer toutes [4, 2]. Toutes les variables sont normalisées dans $[0, 1]$ (min-max) avant combinaison.

4.2. Construction des quatre features composites

- (1) **sleep_quality_index** : $\text{sqi} = \frac{1}{6}(\tilde{d} + \tilde{r} + \tilde{p} + (1 - \tilde{l}) + (1 - \tilde{w}) + \tilde{f})$ — durée, %REM, %profond, latence, réveils, repos ressenti [3]. Corrélation : $r = +0.676$ ($p < 0.001$).
- (2) **mental_load_score** : $\text{mls} = \frac{1}{4}(\tilde{s} + \tilde{m} + \tilde{h} + \tilde{t})$ — stress, santé mentale (Healthy=0 → Both=1), heures de travail, shift work. Corrélation : $r = -0.597$ ($p < 0.001$).
- (3) **lifestyle_score** : $\text{ls} = \frac{1}{3}(\tilde{e} + (1 - \tilde{a}) + \tilde{j})$ — exercice, alcool (inversé), type de jour (week-end=1). Corrélation : $r = +0.502$ ($p < 0.001$).
- (4) **sleep_risk_level** : $\text{srl} = \tilde{k}$ — encodage ordinal normalisé (Healthy=0 → Severe=1), capturant les troubles cliniques du sommeil [3]. Corrélation : $r = -0.680$ ($p < 0.001$).

4.3. Validation des features composites

Deux figures valident nos choix : l'analyse exploratoire (Figure 3) et la visualisation 3D (Figure ??), réalisée *avant* toute modélisation.




Figure 3: Analyse exploratoire des quatre features composites. Ligne du haut : distributions sur les 14851 étudiants. Ligne du bas : corrélations avec `cognitive_performance_score`. Toutes les corrélations sont hautement significatives ($p < 0.001$).

Les quatre features présentent des corrélations fortes et significatives avec la variable cible, et les nuages de points montrent des tendances linéaires nettes, ce qui justifie le recours à la régression linéaire.

4.4. Analyse multidimensionnelle des features composites

La Figure 4 présente une analyse multidimensionnelle de la relation entre nos quatre features handcraftées et le score de performance cognitive des étudiants.




Figure 4: Visualisation multidimensionnelle des quatre features composites vs `cognitive_performance_score` ($N = 14851$ étudiants). **Haut gauche :** plan de régression 3D pour `sleep_quality_index` × `sleep_risk_level` → performance cognitive. **Haut centre :** plan de régression 3D pour `mental_load_score` × `lifestyle_score` → performance cognitive. **Haut droite :** bubble chart — abscisse = `sleep_quality_index`, ordonnée = score cognitif, couleur = `mental_load_score`, taille = `lifestyle_score`. **Bas gauche/droite :** binned scatter de `sleep_quality_index` et `mental_load_score` avec intervalles de confiance et droite de régression.

Justification du choix des features. Cette approche repose sur deux niveaux de justification complémentaires :

1. **Justification conceptuelle** — chaque feature représente un concept physiologique réel et cohérent :
 - `sleep_quality_index` → qualité globale de l'architecture du sommeil
 - `mental_load_score` → charge mentale et psychologique quotidienne
 - `lifestyle_score` → habitudes de vie saines ou délétères
 - `sleep_risk_level` → niveau de risque clinique de trouble du sommeil
2. **Justification visuelle** — la Figure 4 montre que :
 - La relation entre chaque feature et la cible est **linéaire** (tendance binned suit la droite de régression)
 - Les features **varient ensemble** avec le score cognitif de façon cohérente et monotone

- Les tendances observées sont **cohérentes avec la biologie du sommeil** : plus de qualité de sommeil → meilleures performances, plus de charge mentale → moins bonnes performances [3]

“Ces features capturent les 4 dimensions clés du sommeil étudiant et présentent une relation linéaire claire avec les performances cognitives, comme le montre la figure multidimensionnelle. Elles constituent donc une base solide et interprétable pour la régression linéaire développée en Section 5.”

5. Régression linéaire

5.1. Choix du type de régression

Nous avons choisi la **régression linéaire par moindres carrés ordinaires (OLS)**. Ce choix repose sur plusieurs arguments [4, 2] :

1. **Nature de la variable cible** : `cognitive_performance_score` est continue dans $[0, 100]$, approximativement normale (asymétrie = -0.003 , kurtosis = -0.068), ce qui satisfait les hypothèses OLS.
2. **Objectif explicatif** : L'objectif est de quantifier la contribution de chaque facteur via des coefficients interprétables.
3. **Linéarité observée** : Les nuages de points (Section 4) et la visualisation 3D montrent des tendances linéaires nettes.
4. **Alternatives écartées** : La régression logistique (cible non binaire) et softmax (cible non catégorielle) sont inapplicables. La régularisation LASSO/Ridge n'est pas nécessaire avec seulement 4 variables pour $n = 14\,851$ observations.

5.2. Équation du modèle final

Le modèle de régression linéaire multiple ajusté est :

$$\hat{y} = \beta_0 + \beta_1 \cdot \text{sqi} + \beta_2 \cdot \text{mls} + \beta_3 \cdot \text{ls} + \beta_4 \cdot \text{srl} \quad (1)$$

où `sqi` = `sleep_quality_index`, `mls` = `mental_load_score`, `ls` = `lifestyle_score`, `srl` = `sleep_risk_level`.

5.3. Résultats et coefficients




Figure 5: Régression linéaire explicative. Gauche : coefficients standardisés β avec intervalles de confiance à 95 %. Droite : contribution relative de chaque feature à l'explication totale (%). Tous les coefficients sont significatifs à $p < 0.001$.

Variable	β standardisé	Direction	Contribution	p-value
sleep_quality_index	+élevé	↑ positif	27.8 %	< 0.001
lifestyle_score	+6.400	↑ positif	25.8 %	< 0.001
sleep_risk_level	-6.083	↓ négatif	24.5 %	< 0.001
mental_load_score	-5.434	↓ négatif	21.9 %	< 0.001

Les résultats révèlent une répartition remarquablement équilibrée entre les quatre facteurs (27.8 % / 25.8 % / 24.5 % / 21.9 %), confirmant que la performance cognitive est un phénomène **multidimensionnel** : aucun facteur unique ne domine largement. Le **sleep_quality_index** contribue le plus, confirmant que la qualité architecturale du sommeil est le levier principal [3].

5.4. Diagnostic des résidus et validation des hypothèses




Figure 6: Diagnostic des résidus. Haut gauche : résidus vs valeurs ajustées (linéarité et homoscedasticité). Haut centre : Q-Q plot ($r = 0.9999$, Shapiro-Wilk $p = 0.0135$). Haut droite : distribution des résidus ($\mu = 0$, $\sigma = 11.10$). Bas gauche : observé vs prédit ($R^2 = 0.7234$, RMSE = 11.10 pts). Bas centre : corrélations résidus/prédicteurs (toutes proches de zéro). Bas droite : Scale-Location plot (homoscedasticité).

- **Linéarité :** Le graphe résidus vs valeurs ajustées ne montre pas de structure systématique ; la tendance rouge est horizontale autour de zéro.
- **Normalité :** Le Q-Q plot est pratiquement parfait ($r = 0.9999$) ; asymétrie quasi-nulle (-0.003), kurtosis proche de zéro (-0.068). Shapiro-Wilk : $p = 0.0135$ — excellent pour $n = 14\,851$ [4].
- **Homoscedasticité :** Le Scale-Location plot montre une ligne quasi-horizontale, indiquant une variance des résidus constante.
- **Absence de structure résiduelle :** Les corrélations résidus/prédicteurs sont toutes proches de zéro, confirmant que les features composites ont capturé l'essentiel de l'information exploitable.

5.5. Validation croisée à 10 plis




Figure 7: Validation croisée à 10 plis. Gauche : R^2 par pli (stabilité du modèle). Droite : RMSE par pli (erreur de prédiction). La ligne rouge pointillée indique la moyenne ; la bande rose représente $\pm 1\sigma$.

Métrique	Entraînement	Validation croisée
R^2	0.7234	0.7227 ± 0.0096
RMSE	11.10 pts	11.10 ± 0.16 pts
Écart d'overfitting	0.0007 (négligeable)	

Le R^2 varie entre 0.715 et 0.746 selon les plis (plage de 0.031 ; $\sigma = 0.0096$). L'écart d'overfitting ($R^2_{\text{train}} - R^2_{\text{CV}} = 0.0007$) est négligeable, confirmant que le modèle généralise parfaitement aux données non vues.

6. Conclusion

6.1. Apports de cette analyse

Cette analyse démontre que **72.3 % de la variance** de la performance cognitive des étudiants peut être expliquée par seulement quatre variables composites construites manuellement. Le modèle est simultanément puissant ($R^2 = 0.7234$), fiable (overfitting < 0.001) et interprétable (coefficients standardisés avec intervalles de confiance).

Sur le plan pratique, l'analyse génère quatre recommandations actionnables :

1. **Améliorer la qualité globale du sommeil** (β le plus élevé) : dormir 7–9 h, maximiser les phases REM et sommeil profond, réduire les réveils nocturnes [3].
2. **Adopter un style de vie sain** ($\beta = +6.40$) : pratiquer 30 minutes d'activité physique quotidienne, éviter l'alcool avant le coucher.
3. **Réduire le risque de trouble du sommeil** ($\beta = -6.08$) : consulter un médecin en cas de ronflements, insomnies fréquentes ou fatigue chronique.
4. **Gérer la charge mentale** ($\beta = -5.43$) : techniques de gestion du stress, limiter les heures de travail intensif avant de dormir.

6.2. Limites et pistes d'amélioration

Le R^2 de 0.723 laisse 27.7 % de variance inexpliquée. Plusieurs pistes pourraient améliorer ce résultat [4, 2] :

- **Termes d'interaction** : un produit `stress × sleep_risk` pourrait capturer l'effet combiné de ces deux facteurs.
- **Features polynomiales** : un terme quadratique sur le `sleep_quality_index` modéliserait d'éventuels rendements décroissants.
- **Sélection automatique** : une régression LASSO identifierait automatiquement les sous-ensembles optimaux de variables.
- **Modèles non linéaires** : un gradient boosting (XGBoost) pourrait capturer des interactions complexes, au détriment de l'interprétabilité.

Cependant, compte tenu de l'objectif *explicatif* de cette étude, le modèle linéaire reste le choix le plus approprié. Un modèle avec $R^2 = 0.723$, quatre variables interprétables et un overfitting négligeable constitue un résultat scientifiquement rigoureux et directement utilisable pour formuler des recommandations.

References

- [1] *Sleep Health & Lifestyle Dataset* (2024). Jeu de données synthétique, 100 000 enregistrements, 32 variables. Disponible sur Kaggle : <https://www.kaggle.com/datasets/uom190346a/sleep-health-and-lifestyle-dataset>
- [2] Fillatre, L. (2026). *MAM3 — Introduction au Traitement de Données*. Supports de cours, Université Côte d'Azur. Couvre le pipeline de traitement de données, l'ingénierie des features, la régression linéaire et la validation croisée k -fold.
- [3] Walker, M. (2017). *Why We Sleep: Unlocking the Power of Sleep and Dreams*. Scribner. Référence fondamentale sur le rôle du sommeil REM et profond dans la restauration cognitive et la consolidation mémorielle.
- [4] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2^e éd.). Springer. Référence pour la théorie OLS, l'interprétation des coefficients standardisés et la validation croisée.
- [5] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830. Bibliothèque utilisée pour la régression (`LinearRegression`), la standardisation (`StandardScaler`) et la validation croisée (`KFold`, `cross_val_score`).